

数据分析流程（标准版）

数据分析的核心逻辑是：**业务问题** → **数据准备** → **探索分析** → **建模推断** → **结果解释** → **决策建议**。
下面按实际项目流程分为六大步骤。

1 明确问题（Define the Problem）

任何分析都必须从“问题”开始，而不是从“数据”开始。

✓ 需要回答的问题

- 研究目的是什么？（预测 / 解释 / 评价）
- 业务背景是什么？
- 分析对象是谁？
- 输出成果形式是什么？（图表、模型、结论、建议）

✓ 示例

想预测银行客户的违约概率，并寻找影响违约的关键变量，最终用于授信策略。

2 获取数据（Data Collection）

✓ 来源类型

- **内部数据**：交易流水、CRM、运营日志、风控数据等
- **外部数据**：API（如 yfinance）、政府公开数据、第三方数据库、问卷
- **实验数据**：A/B Test、调查数据等

✓ 采集注意事项

- 时间范围一致
- 指标口径清晰
- 权限与隐私合规

3 数据清洗（Data Cleaning）

数据清洗占 60%-70% 的时间，是最费时但最关键的步骤。

✓ 包括

- **缺失值处理**：删除、填补（均值、中位数、插值、模型预测）
- **异常值处理**：箱线图法、Z-score 法、Winsorize
- **格式统一**：时间格式、数字格式、类别变量编码
- **去重**：重复行检查
- **变量构建**：比率变量、对数变换、移动平均、哑变量

✓ 示例

对收益率数据进行 1%-99% 缩尾，构建 $\log(\text{总资产})$ 、增长率、行业哑变量等。

4 探索性分析 (EDA: Exploratory Data Analysis)

EDA 的目的是：**理解数据结构、分布特征、变量关系、潜在模式**。
这一步常用图表与统计量。

✓ 描述统计

- 平均数、中位数、标准差、分位数
- 相关矩阵 (Correlation Matrix)
- 分组统计 (Groupby)

✓ 可视化工具

- Histogram 直方图
- Boxplot 箱线图 (判断离群点)
- Scatter Plot 散点图 (变量关系)
- Heatmap 热力图
- 时间序列折线图

✓ 示例

使用箱线图识别异常值；用散点图检查变量之间是否线性可解释。

5 建模与推断 (Modeling & Inference)

选择模型取决于问题类型：

问题类型	常用方法
预测	回归 (OLS、Lasso)、随机森林、XGBoost、LSTM
分类	逻辑回归、SVM、树模型、神经网络
解释关系	线性回归、面板回归、工具变量回归、因果推断
时间序列	ARIMA、VAR、GARCH、SVAR
聚类	KMeans、DBSCAN、层次聚类

✓ 关键步骤

- 划分训练集、测试集
- 特征工程 (标准化 / 降维 / One-hot)
- 模型训练与调参
- 交叉验证
- 诊断检验 (残差、共线性、稳健性)

✓ 示例

使用面板固定效应模型解释绿色债券收益率的差异，或使用 XGBoost 预测客户违约风险。

6 结果解释 (Interpretation)

✓ 关注内容

- 模型的显著性与系数含义
- 可解释性 (Feature importance)
- 预测效果指标 (R^2 、RMSE、AUC 等)
- 变量变化的边际效应

✓ 示例

发现“绿色认证”对收益率的影响显著为负，说明市场存在“绿色溢价”。

7 可视化输出与报告撰写 (Visualization & Reporting)

✓ 输出形式

- 可视化图表
- 结论总结 (Key Findings)
- 业务建议 (Actionable Insights)
- 限制性说明 (Limitations)

✓ 示例

用 Dashboard 展示模型结果，提出“绿色评级纳入授信评分体系”的建议。

8 迭代优化 (Iteration)

数据分析是一个循环，不是一次完成。

✓ 可能需要反复

- 重新清洗数据
- 引入新的变量
- 尝试不同模型
- 优化参数
- 修正报告



一句话总结整个流程

问题 → 数据 → 清洗 → EDA → 建模 → 解释 → 输出 → 迭代

如果你需要，我可以进一步为你：

- ✓ 做成 **更专业版 / 金融行业专用版**
- ✓ 做成 **绿色金融研究版**
- ✓ 做成 **可以直接放进课件的 PPT 风格版**
- ✓ 或做成 **有图示流程图的版本**

你想用在哪个场景？我可以对应优化。